2027年热门会议推荐

具体咨询:白老师 13516196409

智驱产品技术领航

AI 时代产品和软件开发前沿系列峰会

核心定位

锚定AI 技术革新前沿,聚焦大模型与智能体工程化落地,解构 AI 时代软件工程架构革新路径,打通 AI 产品从技术突破到产品商业化验证的全链路。

关键词

- 大模型驱动
- 技术趋势
- Agent工程化
- 架构革新
- AI产品0-1
- 商业化验证

4月 PM×AI 产品力领航者大会

2027年4月23-24·杭州

详情查看官网
演讲申报 | 参会购票

6月 Agentic AICon 智能体应用与架构工程大会

2027年6月18-19·上海

详情查看官网
演讲申报 | 参会购票

11月 Agentic AICon 智能体应用与架构工程大会

2027年11月5-6日·深圳

AI 赋能提质增效

QECon全球软件质量&效能大会

核心定位

聚焦 AI 技术在软件研发全流程的落地应用,以“质量保障&效能提升”为双驱动,助力研发团队实现软件研发的智能化转型。

关键词

- AI 赋能研发
- 效能提升
- 测试驱动
- 平台工具链
- 质量保障
- .....

5月 QECon 全球软件质量&效能大会

2027年5月21-22·深圳

9月 QECon 全球软件质量&效能大会

2027年9月10-11日·上海

10月 QECon 全球软件质量&效能大会

2027年10月15-16日·北京

演讲申报 | 参会购票
详情查看官网

生产级Agent设计蓝皮书·行业案例卷

"蓝皮书共建计划"启动——行业与场景专家 招募中

白皮书定义模式，蓝皮书记录落地。
把你的生产案例，写进行业参照系。
你的案例，很可能是这个行业第一份模式应用实践指南。

交流地点：《艾普·AI生产力研究院》展位咨询

扫码参与



共建计划

以真实案例为基础，持续组织行业与场景的 Agent 设计模式应用撰写。蓝皮书不写概念，只记录具名系统——它面对什么约束、踩过什么失败、为什么这样选架构、哪些经验可以迁移到你的行业。

我们招募这样的行业与场景专家

主导或深度参与过 Agent 系统建设，有真实跑在生产环境的案例；
在强监管、高可靠或大规模部署约束下做过工程取舍（金融、制造、政务、医疗、能源、电商等皆宜）；
愿意把一段经验，沉淀成可评审、可迁移的模式案例。

参与共建，你将获得

署名蓝皮书案例贡献者，成果进入 ADPS 公共技术资料长期存档；
用白皮书的模式语言系统梳理自己的实践，让团队经验成为行业参照；
参与共同体模块研讨与模式评审，共同界定下一版模式的边界；
与已在共同体的腾讯、蚂蚁、百度、京东等一线专家跨行业互审。

《企业级 Agent 设计白皮书》发布

纸质版 & 电子版 同步上线

领取地点:《艾普·AI生产力研究院》展位

Agent 正在从「会回答问题的模型」变成「能参与业务流程的系统」。模型仍是引擎,但决定它在生产中稳不稳的,是周围这套工程结构。本白皮书给出智能体工程的可复用架构词汇与评审标准。



27	7×6	3	5	6
矩阵模式规范	认知功能 × 执行拓扑	横切工程面 X1–X3	工程契约	步选型法

智能体工程的「GoF设计模式」

27个可复用Agent设计模式双轴框架

企业级智能体架构评审与选型实战手册

双轴框架

纵轴 · 认知功能

Agent 在做什么类型的工作

感知 Perception | 记忆 Memory | 推理 Reasoning | 行动 Action | 反思 Reflection | 协作 Collaboration | 治理 Governance

横轴 · 执行拓扑

数据与控制怎么流动

链式 · 顺序 | 路由 · 分流 | 并行 · 并发 | 编排 · 协调 | 循环 · 迭代 | 层级 · 分层

获取白皮书电子版

艾普·AI生产力研究院

Artificial Intelligence Institute of Productivity

Artificial Intelligence Institute of Productivity · 中立 · 开放 · 共创

面向 AI 原生软件工程的开放研究与实践组织

驾驭智能·定义 AI 时代新质生产力

深度承接《"人工智能+软件"专项行动实施方案》的专业化研究与交流平台

软件质量与效能 | **智能体工程与应用** | **六大研究方向** | **五大核心模块**

艾普 · AI 生产力研究院（AIIP）是一个中立、开放、共创的专业化研究与交流平台。研究院依托在软件质量与效能、智能体工程与应用等前沿领域的长期实践积累与前瞻研究底蕴，汇聚资深技术专家与企业研发团队等各方力量，共同推进行业能力体系建设、参考标准研究与评估框架研制，致力于成为支撑智能软件产业新质生产力发展的专业化交流平台。

更多详情请查看官网：https://aiip.org.cn/

关注官网

申请加入

与先行者同行，共赴 AI 生产力浪潮

六大研究方向

AI for SE

智能软件工程

AI赋能软件开发全流程、AI Coding 生产力与质量保障、智能测试工程，对标智能编程工具链与智能化技改。

度量体系

质效度量与治理

AI 质效度量模型、Token 成本治理、ROI 分析框架，以及成熟度评估参考框架的研究与共建。

ADPS

Agent 设计模式

Agentic 设计模式、多智能体架构、AI 系统技术栈与最佳实践沉淀，对标技能包与应用商店。

FDE

前线部署工程师

工程实践方法论、行业场景适配、企业落地案例与效能提升路径，对标就业友好与重点行业落地。

SE for AI

AI 工程化落地

AI 系统全生命周期工程化方法，可靠性与质量保障，以及 MLOps / LLMOps 交付与治理框架。

AI for X

AI 生产力

AI深度赋能千行百业，从软件研发走向办公、运营、数据、科研等真实业务价值场景，把工程能力转化为可度量的生产力。

AI 质效宣言

发起单位：QECon组委会 QECon Organizing Committee

从共识到行动，让宣言融入每一次研发实践

回归研发本质 **重塑人机协作** **推动行业共识**

协作共生 高于 局部取代
长效质量 高于 短期提效
适应进化 高于 固化流程

价值创造 高于 技术崇拜
数据驱动 高于 经验依赖
开放共享 高于 封闭自建

加入共建计划
获取电子画面

两层能力递进 · 一层工程底座

AI 增强软件研发全景架构

AI 嵌入 SDLC · 效能提升

• 人主导 • AI 协同

需求	设计	开发	测试	CI / CD	运维 / 运营
行业调研与趋势分析	代码理解与逻辑探测	代码生成与缺陷解决	测试用例与数据生成	构建与部署脚本生成	告警聚合与摘要生成
创意启发与功能探索	技术选型与架构设计	氛围编程与规约编程	测试脚本修复与自愈	流水线失败诊断与修复	故障分析与定位
需求分析与规格细化	接口设计与数据模型生成	单元测试生成与执行	端到端测试生成与维护	无人值守部署与发版	故障处理与系统自愈
需求检查与内容评审	技术方案评审与风险分析	代码评审与问题修复	缺陷发现与根因分析	依赖升级与漏洞修复	用户体验与反馈洞察

AI 研发范式变革 • 效能跃迁

• AI 主导 • 人监督

工程实践
- 驾驭工程（模型决定上限，Harness 提升底线）
- 知识工程（跨仓库代码与文档索引 · 沉淀复用）
- 验证闭环（生成 → 验证 → 修正）
- 质量门禁（构建多层次质量防护网）

流程重构
- 意图驱动、面向结果的交付（替代多阶段接力）
- 对齐在前、执行在后（人谈清边界，AI 自主实现）
- 需求即规格、证据即信任（规格成为人机契约）
- 快速原型、持续迭代（沿用敏捷 · 精益研发思想）

组织重塑
- 交付层抹平前后端分工（跨栈交付 · 功能负责人）
- 架构师专注标准与门禁（定标准 · 守门禁）
- 设计师与产品自主交付（部分需求不经研发）
- 先锋队试点后规模复制（先跑通再逐步推广）

效能度量
- 结果面：多 · 快 · 好 · 省
- 过程面：渗透率 · 成熟度 · 使用效果
- 数据源：代码 · 会话 · 配置 · 需求 · 监控
- 北极星：需求交付周期 · 单位 token 有效价值

AI 工程底座 • SE4AI（Software Engineering for AI）

• 自下而上 • 决定能力上限

模型层
- 多模型接入与路由（模型网关 · 按能力与成本择优）
- 能力分级与降级（强弱模型分级 · 故障回退）
- 领域微调与私有化（微调训练 · 内网部署）
- 模型评测与选型（基准跑分 · 场景实测对比）

Agent 层
- Agent 架构与编排（单/多 Agent · 规划与控制流）
- 上下文工程与记忆（上下文组装压缩 · 长短记忆）
- 运行时沙盒与工具接入（隔离执行 · MCP 与技能调用）
- 灰度发布与回滚（能力评估达标才放量 · 版本化 · 自动回退）

生态层
- 技能与智能体市场（技能复用 · Agent 共享流通）
- MCP Hub 与工具生态（工具目录 · 权限与调用治理）
- 知识资产与语料沉淀（业务知识 · 代码知识 · 过程知识）
- 检索服务与知识图谱（语义检索 · 图谱关系推理）

贯穿三层 | **安全与治理** 数据脱敏 · 提示注入防护 · 最小授权 · 输出合规 | **可观测性** 决策链路追踪 · 上下文溯源 · 失败归因 | **能力评估** 任务成功率 · 人工接管率 · 单任务成本

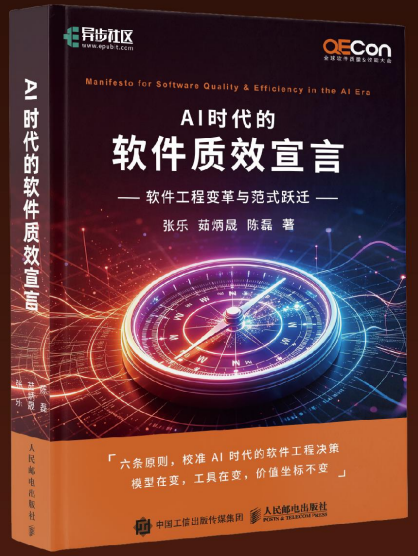
为每一位实践者提供一组稳定的价值坐标——当工具在变、模型在变、最佳实践在变的时候，这些原则帮你判断什么是不变的、什么是值得坚守的。

AI 时代的软件质效宣言

新书发布

— 软件工程变革与范式跃进 —

扫码订阅



系列电子书结构·三篇十九章 (道 · 术 · 势 —— 一条完整的 AI 研发变革路径)

道

第一篇 · 解读篇 (1-8 章)

确立价值观与原则：理解 AI 时代软件质效的本质，重建研发协作的信念底座，是全书的「道」。

术

即将发布

第二篇 · 单点提效篇 (9-14 章)

覆盖需求分析 → 架构设计 → 编码实现 → 测试验证 → CI/CD → 运维运营的关键环节，打通 AI 赋能研发全链路，是全书的「术」。

势

即将发布

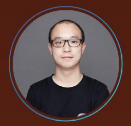
第三篇 · 范式篇 (15-19 章)

当 AI 贯穿整条研发链路之后，组织形态本身将如何变革？从团队结构到协作范式，预见未来，是全书的「势」。

—— 主编 ——



张乐
腾讯
智能化软件工程
资深技术专家

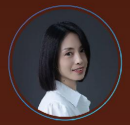


茹炳晟
腾讯研究院
高级技术顾问



陈磊
前京东测试架构师

—— 作者 ——



王玉霞
北京兴云数科
过程改进专家



李佳奇
去哪儿旅行
技术总监



牛万鹏
百度
Comate研发经理



张晔
腾讯端服务质效
技术负责人



张涛
快手质量通道委员



付求爱
华为云
AIOps技术负责人



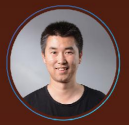
李萌
珊瑚智成
创始人&CEO



张刚
上海英慕科技
资深技术专家



张兆鑫
OPPO AI架构师



王磊
华为 AI技术专家

主办方：智盟创课

智盟创课（北京）科技有限公司（简称“智盟 Stu.”），作为专业IT产研培训服务供应商与AI时代数字化人才发展伙伴，为科技研发型企业及各类组织提供系统性、分层次、重实战的人才培养解决方案，同时搭建行业前沿技术交流平台，致力于成为企业数字化转型进程中人才培养与业务创新的核心支撑力量，推动组织实现成功转型及经营业绩持续增长。

同时，智盟发起并组织三大 IT 领域品牌会议：QECon 软件质量效能大会、SECon+AgentX 智能时代软件工程技术大会、PMxAI 产品力领航者大会、Agentic AICon 智能体应用与架构工程大会，助力产研中心深化数字化转型、聚焦业务价值达成，在产品研发的快速交付与高质量发展之间找到平衡，打通企业全维度学习视角，最终实现人才能力提升与企业竞争优势增强的双重目标。



详情咨询: 010-65798049

多元化学习形式



核心培训方向



软件研发赋能

大模型前沿	架构设计	数据库	产品经理	持续运维	质量管理
移动开发	组织管理	云计算	开发编程	敏捷开发	大数据

Agentic AICon

Agent 系统中的大小模型协作

有限算力下的企业研发架构实践

蒋思源 / aiXcoder 算法专家





蒋思源

硅心科技算法工程师

长期从事代码模型与行业大模型研发，2020年以来，围绕代码生成、端侧部署、结构化表示、项目级上下文和推理加速，持续推进从4M到百B参数、从百亿到万亿级语料的训练实践，完成国产于英伟达大规模分布式训练、数据处理、模型蒸馏、OPD、RL和多LoRA推理系统建设。近年来聚焦垂直领域的后训练，包括通信网络、SWE与Agent专用模型，形成从数据、模型、训练到推理部署的完整技术积累。

我们的模型与推理工程实践

01 / 系统认识

持续把任务能力与运行条件放在一起设计

2019—2020

端侧小模型

代码表示

模型压缩与 CPU 部署

2021—2024

企业领域适配

参数高效训练

项目上下文与推理工程

2025

专业任务训练

领域知识

多轮检索与工具使用

2026

Agent 专精服务

Apply / Pruner / Compact

领域模型与统一推理调度

长期关注：给定任务与硬件条件，怎样获得可用能力

企业 Agent 的资源约束

质量、等待时间与并发容量共同决定可用性

同一套算力
需要服务
更多研发任务

私有部署	代码、数据与推理服务留在企业环境
并发使用	多个团队同时调用有限模型实例
长任务	历史与工具输出持续占用上下文
交互体验	排队与执行耗时影响工作节奏

一次 Agent 任务的执行过程

01 / 系统认识

不同步骤有不同的能力需求与开销

理解需求 目标与约束 → **读取材料** 文件与检索 → **修改代码** 生成与落盘 → **运行验证** 测试与工具 → **分析反馈** 继续或结束

将重复执行与上下文处理交给专精模型

模型计算

主模型与专精服务

工具执行

测试、编译与仿真

排队等待

请求、实例与共享资源

沿任务链路识别高频、耗时且可专精的工作

大小模型协作的三种方式

01 / 系统认识

从一次调用到一段有边界的工作流

01

步骤委托

aiXapply

融合修改片段
保持其余代码

02

上下文处理

aiXpruner / aiXcompact

筛选新增证据
整理累积任务历史

03

子任务委托

专业检索 / RTL 生成修复

接收目标与预算
运行局部工具循环

把通用执行、上下文处理与领域子任务封装成可复用的小模型服务

小模型接管高频消耗，大模型聚焦思考

01 / 核心思想

按推理难度与领域专长分工，让算力投入最有价值的步骤

优先交给小模型

高 Token、耗时长、推理浅

全文融合、日志筛选、历史整理

领域特性强，通用模型覆盖不足

用领域数据和工具反馈训练专用模型

候选清楚的简单决策

相关性、分类、路由与优先级

保留给大模型

复杂思考与全局规划

理解目标、拆解问题、形成解决方案

跨模块与开放式推理

处理歧义、建立假设、设计新动作

复杂决策与异常升级

综合多方证据，处理专精模型未覆盖问题

aiXapply 把全文落盘交给 4B 模型

02 / aiXapply

大模型已经决定怎么改，剩下的大量全文输出可以专门优化

为什么做

修改片段很短
完整文件却很长

主模型反复输出未改动代码
占用生成时间与服务容量

还要处理定位、占位符展开
以及原文件内容的准确保留

怎样协作

主模型

分析问题，生成修改片段

↓

aiXapply 4B

融合全文，保留未改动区域

↓

IDE / Agent

展示差异，继续测试与迭代

aiXapply 的数据与训练

真实代码修改提供目标，SFT 与 GRPO 分别学习融合和副作用控制

真实 Commit
原文件 / 新文件

→

构造修改片段
变更说明 / 占位符

→

一致性与可解过滤
核对片段和目标文件

→

Qwen3-4B 训练
SFT / GRPO

24,460 候选样本 → **20,984** 过滤后样本 = **19,347** 训练 + **1,637** 测试

SFT 监督

学习完整目标文件
同时学习修改部分与原文保留

RL 奖励

等价匹配奖励 + 错误类型反馈
对修改区域之外的副作用施加更高惩罚

Apply 的规则奖励与修改边界

定位并合入指定修改，其他区域保持词法一致

只允许修改指定区域

```
def normalize(x):
    return x.strip()

def retries():
    return 5  # 原值为 3

DEFAULT_TIMEOUT = 30
```

按修改结果给出确定性反馈

正确合入指定修改	等价奖励 r = 1
目标修改未完成	计入 E_patch
改动了区域外代码	计入 E_outside

$$r = \max(0, 1 - \alpha E_{patch} - \beta E_{outside})$$

β > α：对目标区域之外的意外改动施加更高惩罚

先判断全文等价性，再用错误类型为失败样本提供更细的训练信号

aiXapply 的质量与推理效率

论文原表：主测试集的模型对比与投机解码效率

Table 3. 主测试集结果

原表摘录 Model / Avg 两列，保留全部模型

Model/Language	Avg
Qwen3-4B	0.626
DeepSeek-v3.2	0.916
Qwen3.5-397B-A17B	**0.948**
GLM-5	0.921
Fast-Apply-7B	0.620
aiXapply-RL	0.938
aiXapply-SFT	0.944

Table 8. 不同解码策略的效率

单张 A100 40GB，完整测试集 1,637 条

Table 8: Key efficiency results across decoding strategies.

Method	Avg Latency (s)	P95 (s)	Throughput (tokens/s)
Baseline (no speculation)	28.83	90.23	102.04
Suffix (default)	5.75	20.74	509.54
N-gram (default)	2.17	6.94	1343.99
N-gram (best, n=7, k=128)	**1.06**	**3.38**	**2692.01**

IDE 部署记录

平均 Apply 延迟 50.00 s → 1.89 s

P95 延迟 89.00 s → 3.78 s

aiXcompact 的结构化压缩任务

历史不断增长时，既要减少上下文，也要让后续 Agent 接得上任务

① 整体分析

`<aix_analysis>`

理解任务全貌

用户目标与关键约束

当前进展与已验证结论

错误、修复与未完成工作

决定哪些信息影响后续执行

② 逐轮 CoT 与判断

`<aix_decisions>`

为每条消息给出依据

item_analysis：为什么保留或压缩

keep：保留原始消息

replace：压缩工具返回

remove：删除冗余消息

按消息 ID 输出动作与替换内容

③ 任务总结

`<aix_summary>`

承接被删除的关键信息

保留目标、约束与重要决策

记录错误及有效修复

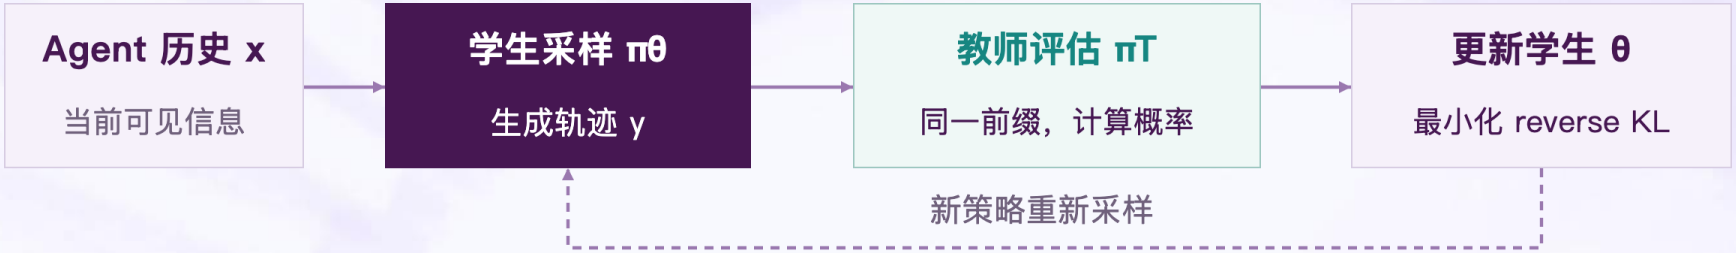
明确当前工作与下一步

删除历史时，重要事实仍有归处

交给后续 Agent　任务总结 ＋ 保留的消息 ＋ 替换后的工具结果

OPD 的训练原理

学生生成轨迹，教师在同一前缀下提供逐 Token 监督



Reverse KL：学生分布接近教师分布

$$D_{\mathrm{KL}}(\pi_\theta(\cdot \mid h_t) \| \pi_{\mathrm{T}}(\cdot \mid h_t)) = \mathbb{E}_{y_t \sim \pi_\theta(\cdot \mid h_t)}[\log \frac{\pi_\theta(y_t \mid h_t)}{\pi_{\mathrm{T}}(y_t \mid h_t)}]$$

逐 Token 蒸馏信号

$$r_t = \log \pi_{\mathrm{T}}(y_t \mid h_t) - \log \pi_\theta(y_t \mid h_t)$$

$$h_t = (x, y_{<t})$$

前缀来自学生，教师参数保持冻结

aiXcompact 将上下文压至约四分之一

02 / aiXcompact

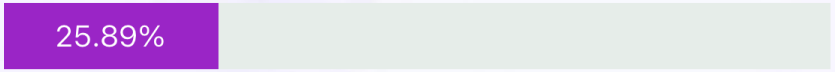
以 4B 模型提供可部署的历史整理能力

平均上下文保留率

压缩前



压缩后



74.11% 平均上下文减少

全部样本，失败按原文保留

质量与部署

指标	Compact 4B	教师参考
规则综合分	0.7012	0.7332
信息保留规则分	0.4981	0.4968

单张 A100 40GB

已验证部署与 OpenCode 接入

aiXpruner 的抽取式工具上下文优化

02 / aiXpruner

4B 模型判断相关性，程序从原始输出中提取证据

一次工具结果的处理

01 **MCP 执行 bash / read_file**

捕获完整原文，按片段 ID 分段

02 **Qwen3.5-4B 选择相关范围**

输入当前关注的问题与片段，输出 keep_ranges

03 **校验 ID，从原文重建结果**

代码、堆栈与日志保留原始内容和出处

MCP 接入　分批与并发处理　异常返回完整原文

审计后的工程效果

指标	结果
工具结果处理	4,765 次
原始字符量	29.78 M
返回字符量	26.51 M
字符量减少	**10.98%**

保留内容可追溯到原文

适用于测试、构建与代码读取

Agentic RAG 将多轮检索交给 4B 模型

03 / Agentic RAG

把查资料、补证据和整理上下文委托出去，主 Agent 保留综合决策

主 Agent
给出调研目标

→

4B ReAct Agent
查询、补查、提炼

→

Milvus RAG
领域文档与代码

→

证据包
出处、原文与总结

检索结果返回 ReAct，按证据缺口继续查找与整理

数据构造

从领域代码与文档生成问答
保留参考回答、证据文件和行号

多轮 Agentic RL

采样检索与总结轨迹
只对模型动作计算训练损失

证据与结果监督

格式、路径与行段覆盖
代理答案正确性奖励

长程 Agent 任务：奖励如何落到动作

03 / Agentic RAG 奖励与信用分配

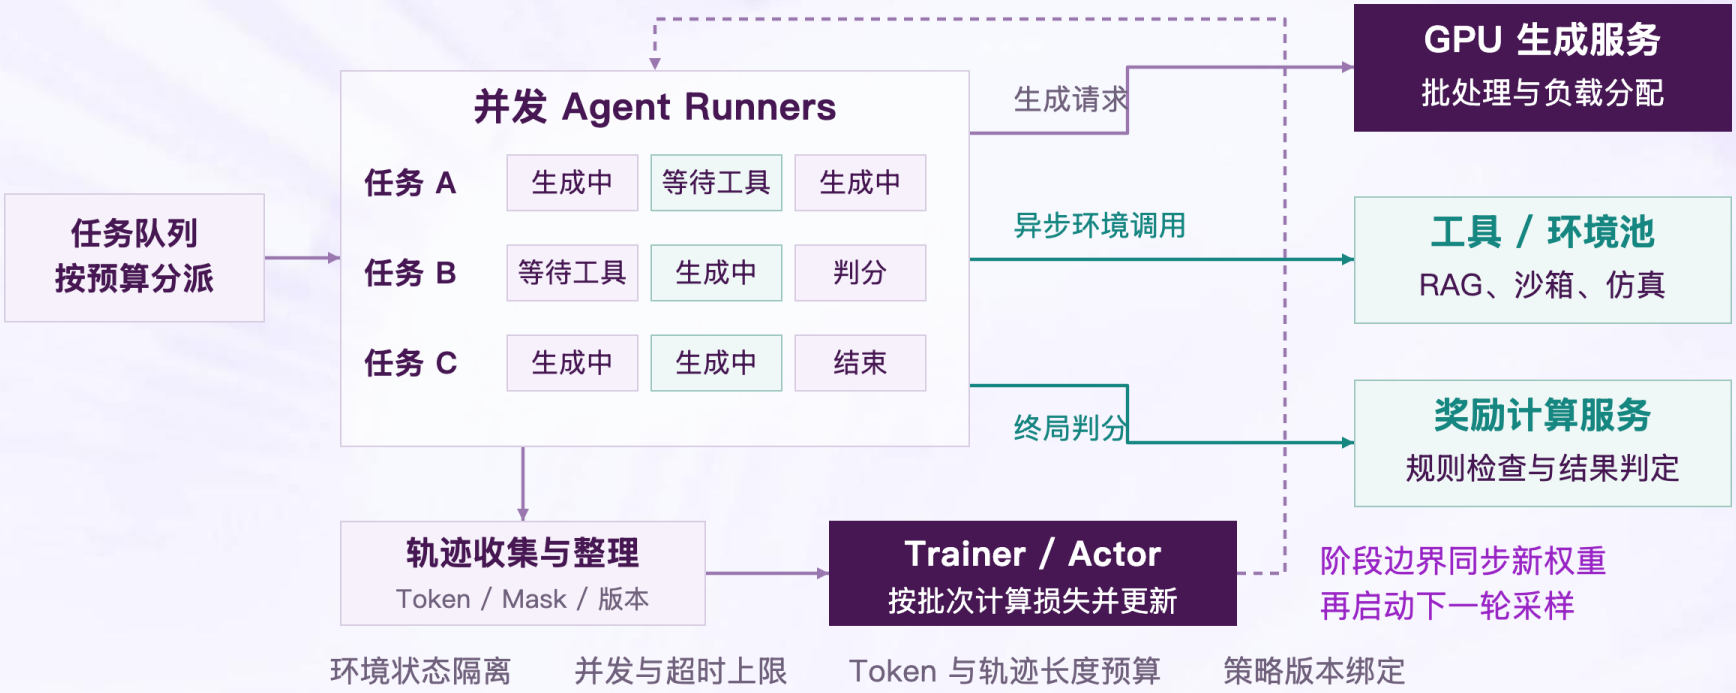
区分终局评价、过程反馈与动作 Token 的训练归属



流程强制注入 Token 同样置 0，保留为上下文供后续动作使用

Agentic RL：采样与环境的并发调度

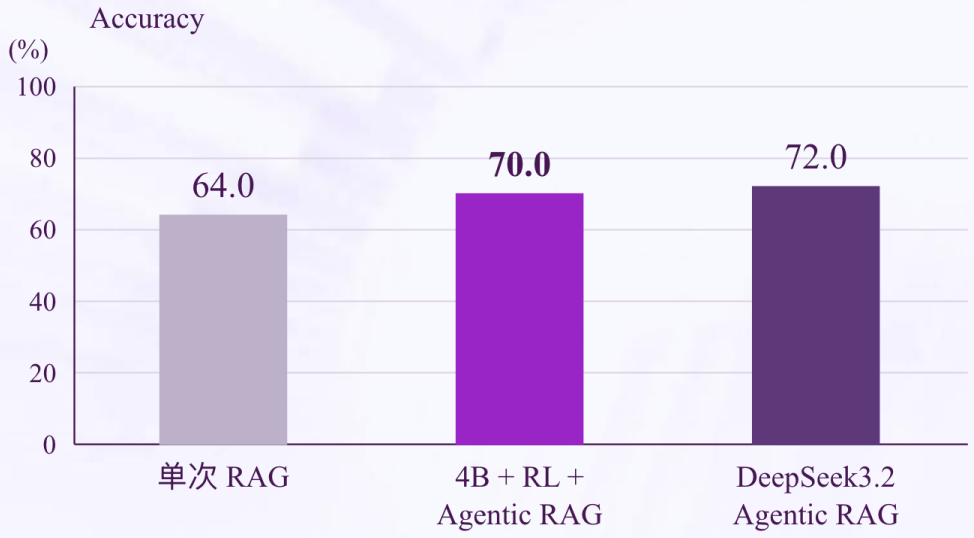
将 GPU 推理、工具等待与奖励计算分开组织



Agentic RAG 的效果与上下文对比

主 Agent 统一使用 DeepSeek3.2，比较三种检索方案

(a) 问答准确率：使用召回 Context



(b) 主 Agent 上下文长度

方案	平均长度	长度变化
单次 RAG	8K	基准
4B + RL + Agentic RAG	**6K**	**−25.0%**
DeepSeek3.2 Agentic RAG	27K	+237.5%

平均背景上下文，单位 Token；变化相对单次 RAG

4B 方案较大模型 Agentic RAG 返回上下文减少 **77.8%**

DecisionModel 承担高频简单判断

03 / DecisionModel

在有限候选中做选择，复杂规划与开放式决策仍由主模型完成

01

读取与上下文

筛选相关文件与日志

重排检索候选

识别需要保留的证据

02

工具与模型选择

选择已有工具或技能

匹配模型能力档位

判断何时升级到大模型

03

进展与验证

识别重复尝试与停滞

排列检查优先级

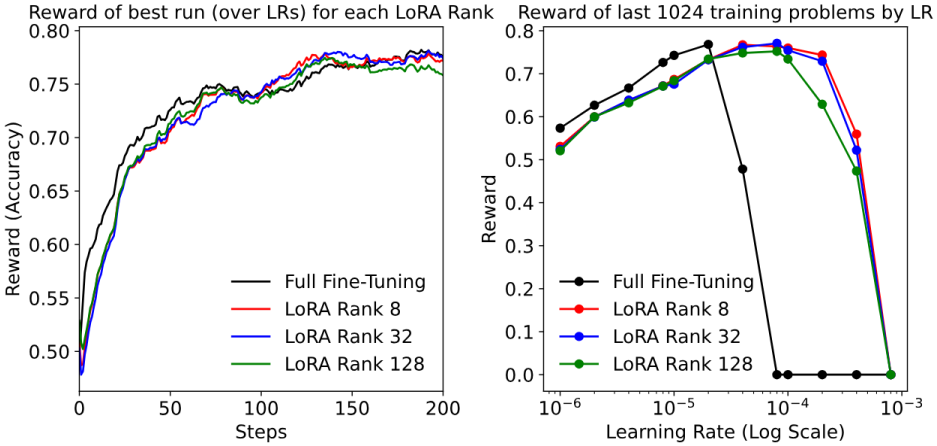
提醒尚缺哪些验证证据

接入形式：任务状态 + 简单问题 + 有限候选，输出选择、排序或评分

选择 LoRA 后训练的研究依据

04 / 多 LoRA 训练与调度

RL 学习效果与训练资源共同支撑选型



研究观察

在所测数学 RL 设置中
LoRA 与全参达到相近学习效果

工程选择

减少训练状态占用
独立管理任务 adapter
共享基座提供服务

Qwen3-8B-Base / DeepMath；应用层、学习率和任务容量影响结果

多 LoRA 让专精能力共享推理资源

04 / 训练与推理系统

围绕兼容基座训练不同任务能力，减少每项服务重复加载完整模型

主 Agent 按任务调用小模型能力

代码融合	历史压缩	领域任务	简单决策
Apply	Compact	RTL / RAG	DecisionModel
Adapter A	Adapter B	Adapter C	Adapter D

兼容基座服务池

共享基础权重

按任务迭代能力

集中管理版本与资源

统一调度主模型与专精服务

04 / 训练与推理系统

按请求特征组织实例、批次与显存，让有限资源承载更多并发

业务请求

交互式任务

Apply / 简单决策

长上下文任务

Compact / 大文件

领域工作流

RTL / Agentic RAG

统一调度

模型与 adapter 路由

长短请求分组与批处理

并发配额与显存预算

热点驻留与独立实例

围绕任务时限与吞吐安排资源

执行资源

主模型服务池

规划与复杂推理

小模型服务池

共享基座与专精能力

验证工具资源

CPU / 仿真 / 综合

Benchmark 同时比较能力与投入

04 / 训练与推理系统

以通用大模型为对照，找到每个任务适合的质量与成本组合

任务级对照

任务	效果指标	效率指标
Apply	融合等价与未改动区域保持	落盘延迟 / 输出吞吐
Compact / Pruner	信息保留与上下文缩减	处理耗时 / 后续输入量
RTL / RAG	功能验证 / 证据问答效果	迭代轮数 / 工具与模型成本

系统级收益

同一算力预算

合格任务数 / 小时

端到端 P50 / P95

单位成功任务完整成本

所有尝试总成本
÷
成功任务数

一套小模型服务，覆盖不同企业任务

Agentic AICon

05 / 企业价值

把高频消耗、领域专长和简单判断沉淀为可复用能力

aiXapply

高效完成代码落盘

aiXcompact

压缩历史，支持持续执行

aiXpruner

保留关键工具证据

aiXverilog

承接硬件生成与修复

Agentic RAG

多轮查证并返回精简上下文

DecisionModel

快速完成有限空间判断

大模型集中处理思考与规划，小模型服务体系持续扩展企业能力

Takeaways

05 / 总结

企业 Agent 的效率，来自能力分工、专精训练与资源协同

01 把大模型留给思考，把高频工作交给小模型

复杂规划与决策由大模型负责，高频执行、简单判断与领域任务由专精服务承接。

02 从真实工程反馈中，训练出可复用的专长

以 Commit、Agent 轨迹和工具验证为基础，按任务选择蒸馏、OPD 与 RL。

03 把模型优势转化为可衡量的系统收益

多 LoRA 与统一调度共享资源，以任务质量、延迟和单位成功任务成本检验收益。

目标：同等算力下，完成更多高质量任务

Agentic AICon

智能体应用与架构工程大会

交流与问答

关注公众号

更多会议详情