2027年热门会议推荐

具体咨询：白老师 13516196409

智驱产品技术领航

AI 时代产品和软件开发前沿系列峰会

核心定位

锚定AI 技术革新前沿，聚焦大模型与智能体工程化落地，解构 AI 时代软件工程架构革新路径，打通 AI 产品从技术突破到产品商业化验证的全链路。

关键词

- 大模型驱动
- 技术趋势
- Agent工程化
- 架构革新
- AI产品0-1
- 商业化验证

PM×AI 产品力领航者大会

2027年4月23-24·杭州

详情查看官网
演讲申报｜参会购票

AgenticAICon 智能体应用与架构工程大会

2027年6月18-19·上海

详情查看官网
演讲申报｜参会购票

AgenticAICon 智能体应用与架构工程大会

2027年11月5-6日·深圳

4月 · 5月 · 6月 · 9月 · 10月 · 11月

AI 赋能提质增效

QECon全球软件质量&效能大会

QECon 全球软件质量&效能大会

2027年5月21-22·深圳

QECon 全球软件质量&效能大会

2027年9月10-11日·上海

QECon 全球软件质量&效能大会

2027年10月15-16日·北京

演讲申报｜参会购票
详情查看官网

核心定位

聚焦 AI 技术在软件研发全流程的落地应用，以“质量保障&效能提升”为双驱动，助力研发团队实现软件研发的智能化转型。

关键词

- AI 赋能研发
- 效能提升
- 测试驱动
- 平台工具链
- 质量保障
- .....

生产级Agent设计蓝皮书·行业案例卷

"蓝皮书共建计划"启动——行业与场景专家 招募中

白皮书定义模式，蓝皮书记录落地。
把你的生产案例，写进行业参照系。
你的案例，很可能是这个行业第一份模式应用实践指南。

交流地点：《艾普·AI生产力研究院》展位咨询

扫码参与



共建计划

以真实案例为基础，持续组织行业与场景的 Agent 设计模式应用撰写。蓝皮书不写概念，只记录具名系统——它面对什么约束、踩过什么失败、为什么这样选架构、哪些经验可以迁移到你的行业。

我们招募这样的行业与场景专家

主导或深度参与过 Agent 系统建设，有真实跑在生产环境的案例；
在强监管、高可靠或大规模部署约束下做过工程取舍（金融、制造、政务、医疗、能源、电商等皆宜）；
愿意把一段经验，沉淀成可评审、可迁移的模式案例。

参与共建，你将获得

署名蓝皮书案例贡献者，成果进入 ADPS 公共技术资料长期存档；
用白皮书的模式语言系统梳理自己的实践，让团队经验成为行业参照；
参与共同体模块研讨与模式评审，共同界定下一版模式的边界；
与已在共同体的腾讯、蚂蚁、百度、京东等一线专家跨行业互审。

《企业级 Agent 设计白皮书》发布

纸质版 & 电子版 同步上线

领取地点:《艾普·AI生产力研究院》展位

Agent 正在从「会回答问题的模型」变成「能参与业务流程的系统」。模型仍是引擎,但决定它在生产中稳不稳的,是周围这套工程结构。本白皮书给出智能体工程的可复用架构词汇与评审标准。



27	7×6	3	5	6
矩阵模式规范	认知功能 × 执行拓扑	横切工程面 X1–X3	工程契约	步选型法

智能体工程的「GoF设计模式」

27个可复用Agent设计模式双轴框架

企业级智能体架构评审与选型实战手册

双轴框架

纵轴 · 认知功能

Agent 在做什么类型的工作

感知 Perception | 记忆 Memory | 推理 Reasoning | 行动 Action | 反思 Reflection | 协作 Collaboration | 治理 Governance

横轴 · 执行拓扑

数据与控制怎么流动

链式 · 顺序 | 路由 · 分流 | 并行 · 并发 | 编排 · 协调 | 循环 · 迭代 | 层级 · 分层

获取白皮书电子版

艾普·AI生产力研究院
Artificial Intelligence Institute of Productivity

Artificial Intelligence Institute of Productivity · 中立 · 开放 · 共创

面向 AI 原生软件工程的开放研究与实践组织

驾驭智能·定义 AI 时代新质生产力

深度承接《"人工智能+软件"专项行动实施方案》的专业化研究与交流平台

软件质量与效能 | **智能体工程与应用** | **六大研究方向** | **五大核心模块**

艾普 · AI 生产力研究院（AIIP）是一个中立、开放、共创的专业化研究与交流平台。研究院依托在软件质量与效能、智能体工程与应用等前沿领域的长期实践积累与前瞻研究底蕴，汇聚资深技术专家与企业研发团队等各方力量，共同推进行业能力体系建设、参考标准研究与评估框架研制，致力于成为支撑智能软件产业新质生产力发展的专业化交流平台。

更多详情请查看官网：https://aiip.org.cn/

关注官网

申请加入

与先行者同行，共赴 AI 生产力浪潮

六大研究方向

AI for SE
智能软件工程

AI赋能软件开发全流程、AI Coding 生产力与质量保障、智能测试工程，对标智能编程工具链与智能化技改。

度量体系
质效度量与治理

AI 质效度量模型、Token 成本治理、ROI 分析框架，以及成熟度评估参考框架的研究与共建。

ADPS
Agent 设计模式

Agentic 设计模式、多智能体架构、AI 系统技术栈与最佳实践沉淀，对标技能包与应用商店。

FDE
前线部署工程师

工程实践方法论、行业场景适配、企业落地案例与效能提升路径，对标就业友好与重点行业落地。

SE for AI
AI 工程化落地

AI 系统全生命周期工程化方法，可靠性与质量保障，以及 MLOps / LLMOps 交付与治理框架。

AI for X
AI 生产力

AI深度赋能千行百业，从软件研发走向办公、运营、数据、科研等真实业务价值场景，把工程能力转化为可度量的生产力。

AI 质效宣言

发起单位：QECon组委会 QECon Organizing Committee

从共识到行动，让宣言融入每一次研发实践

回归研发本质 **重塑人机协作** **推动行业共识**

协作共生 高于 局部取代
长效质量 高于 短期提效
适应进化 高于 固化流程
价值创造 高于 技术崇拜
数据驱动 高于 经验依赖
开放共享 高于 封闭自建

加入共建计划
获取电子画面

两层能力递进 · 一层工程底座

AI 增强软件研发全景架构

AI 嵌入 SDLC · 效能提升

• 人主导 • AI 协同

需求
- 行业调研与趋势分析
- 创意启发与功能探索
- 需求分析与规格细化
- 需求检查与内容评审

设计
- 代码理解与逻辑探测
- 技术选型与架构设计
- 接口设计与数据模型生成
- 技术方案评审与风险分析

开发
- 代码生成与缺陷解决
- 氛围编程与规约编程
- 单元测试生成与执行
- 代码评审与问题修复

测试
- 测试用例与数据生成
- 测试脚本修复与自愈
- 端到端测试生成与维护
- 缺陷发现与根因分析

CI / CD
- 构建与部署脚本生成
- 流水线失败诊断与修复
- 无人值守部署与发版
- 依赖升级与漏洞修复

运维 / 运营
- 告警聚合与摘要生成
- 故障分析与定位
- 故障处理与系统自愈
- 用户体验与反馈洞察

AI 研发范式变革 · 效能跃迁

• AI 主导 • 人监督

工程实践
- 驾驭工程 （模型决定上限，Harness 提升底线）
- 知识工程 （跨仓库代码与文档索引 · 沉淀复用）
- 验证闭环 （生成 → 验证 → 修正）
- 质量门禁 （构建多层次质量防护网）

流程重构
- 意图驱动、面向结果的交付 （替代多阶段接力）
- 对齐在前、执行在后 （人谈清边界，AI 自主实现）
- 需求即规格、证据即信任 （规格成为人机契约）
- 快速原型、持续迭代 （沿用敏捷 · 精益研发思想）

组织重塑
- 交付层抹平前后端分工 （跨栈交付 · 功能负责人）
- 架构师专注标准与门禁 （定标准 · 守门禁）
- 设计师与产品自主交付 （部分需求不经研发）
- 先锋队试点后规模复制 （先跑通再逐步推广）

效能度量
- 结果面：多 · 快 · 好 · 省
- 过程面：渗透率 · 成熟度 · 使用效果
- 数据源：代码 · 会话 · 配置 · 需求 · 监控
- 北极星：需求交付周期 · 单位 token 有效价值

AI 工程底座 · SE4AI （Software Engineering for AI）

• 自下而上 • 决定能力上限

模型层
- 多模型接入与路由 （模型网关 · 按能力与成本择优）
- 能力分级与降级 （强弱模型分级 · 故障回退）
- 领域微调与私有化 （微调训练 · 内网部署）
- 模型评测与选型 （基准跑分 · 场景实测对比）

Agent 层
- Agent 架构与编排 （单/多 Agent · 规划与控制流）
- 上下文工程与记忆 （上下文组装压缩 · 长短记忆）
- 运行时沙盒与工具接入 （隔离执行 · MCP 与技能调用）
- 灰度发布与回滚 （能力评估达标才放量 · 版本化 · 自动回退）

生态层
- 技能与智能体市场 （技能复用 · Agent 共享流通）
- MCP Hub 与工具生态 （工具目录 · 权限与调用治理）
- 知识资产与语料沉淀 （业务知识 · 代码知识 · 过程知识）
- 检索服务与知识图谱 （语义检索 · 图谱关系推理）

贯穿三层 | **安全与治理** 数据脱敏 · 提示注入防护 · 最小授权 · 输出合规 | **可观测性** 决策链路追踪 · 上下文溯源 · 失败归因 | **能力评估** 任务成功率 · 人工接管率 · 单任务成本

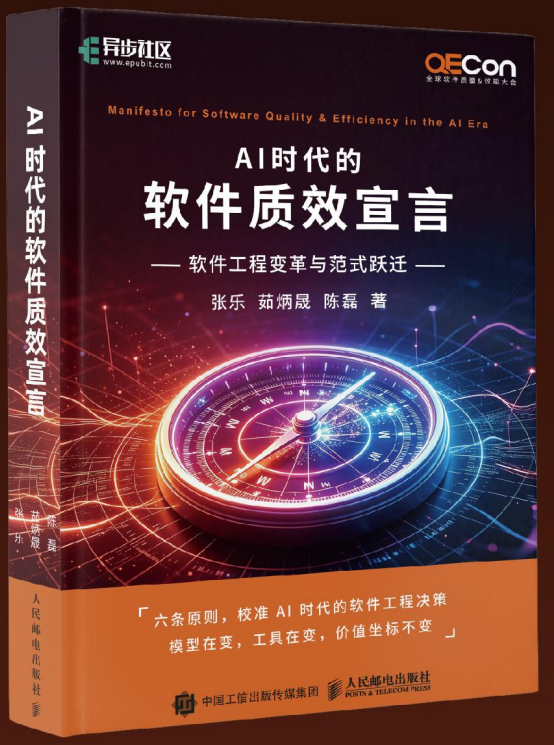
为每一位实践者提供一组稳定的价值坐标——当工具在变、模型在变、最佳实践在变的时候，这些原则帮你判断什么是不变的、什么是值得坚守的。

AI 时代的软件质效宣言

新书发布

— 软件工程变革与范式跃进 —

扫码订阅



系列电子书结构·三篇十九章 (道 · 术 · 势 —— 一条完整的 AI 研发变革路径)

道

第一篇 · 解读篇 (1-8 章)

确立价值观与原则：理解 AI 时代软件质效的本质，重建研发协作的信念底座，是全书的「道」。

术

即将发布

第二篇 · 单点提效篇 (9-14 章)

覆盖需求分析 → 架构设计 → 编码实现 → 测试验证 → CI/CD → 运维运营的关键环节，打通 AI 赋能研发全链路，是全书的「术」。

势

即将发布

第三篇 · 范式篇 (15-19 章)

当 AI 贯穿整条研发链路之后，组织形态本身将如何变革？从团队结构到协作范式，预见未来，是全书的「势」。

—— 主编 ——



张乐
腾讯
智能化软件工程
资深技术专家



茹炳晟
腾讯研究院
高级技术顾问



陈磊
前京东测试架构师

—— 作者 ——



王玉霞
北京兴云数科
过程改进专家



李佳奇
去哪儿旅行
技术总监



牛万鹏
百度
Comate研发经理



张晔
腾讯端服务质效
技术负责人



张涛
快手质量通道委员



付求爱
华为云
AIOps技术负责人



李萌
珊瑚智成
创始人&CEO



张刚
上海英慕科技
资深技术专家



张兆鑫
OPPO AI架构师



王磊
华为 AI技术专家

主办方：智盟创课

智盟创课（北京）科技有限公司（简称“智盟 Stu.”），作为专业IT产研培训服务供应商与AI时代数字化人才发展伙伴，为科技研发型企业及各类组织提供系统性、分层次、重实战的人才培养解决方案，同时搭建行业前沿技术交流平台，致力于成为企业数字化转型进程中人才培养与业务创新的核心支撑力量，推动组织实现成功转型及经营业绩持续增长。

同时，智盟发起并组织三大 IT 领域品牌会议：QECon 软件质量效能大会、SECon+AgentX 智能时代软件工程技术大会、PMxAI 产品力领航者大会、Agentic AICon 智能体应用与架构工程大会，助力产研中心深化数字化转型、聚焦业务价值达成，在产品研发的快速交付与高质量发展之间找到平衡，打通企业全维度学习视角，最终实现人才能力提升与企业竞争优势增强的双重目标。



详情咨询: 010-65798049

多元化学习形式

技术峰会 → 公开课 → 内训定制 → 微咨询 → 在线课程

核心培训方向

AI大模型应用 | 产品运营提升 | 数据分析决策 | 通用管理赋能 | AI职场综合应用

软件研发赋能

大模型前沿	架构设计	数据库	产品经理	持续运维	质量管理
移动开发	组织管理	云计算	开发编程	敏捷开发	大数据

Agentic AICon

评测即奖励：Agent 自进化时代的评测范式重建

周依涛 | 腾讯广告 研发工程师





周依涛

- 腾讯广告研发工程师，公司级讲师，司内 AI 社群创始人，播客嘉宾

- 腾讯广告研发工程师，长期深耕**广告数据平台**，负责海量数据从接入、治理、管控到应用的全链路建设，持续探索 AI 深度参与研发与质量保障的实践路径。
- 当前，专注于 Agent 工程化与评测，主导构建评测驱动的 Agent 自进化体系，推动 Agent 从“用过即忘”走向“越用越准”，已在研发、运维、安全与业务增长等核心场景**规模化落地**。
- 相关实践多次获评腾讯内部提效**优秀案例**，并荣获**公司级 AI 作品**奖项。
- 近半年，在司内外发表 Agent 系列文章，总浏览量**超 10 万**；
- 在腾讯学堂**讲授** Harness 工程实践课程，受邀**做客 AI 主题播客**分享一线思考
- **创办**司内 AI 技术社群，连接跨团队实践者，促进经验沉淀与共享。

目录

01 范式迁移
评测为什么变成了「奖励」

02 五类病灶
当评测成为奖励，会出什么事

03 进化飞轮
怎么让信号真正流动起来

04 实战拆解
三类任务，三条不同的路

05 人与组织
机器越自动，人越关键

OPENING · 开场

序

一个扎心的问题

你的 Agent 上线半年，
它真的比第一天更聪明了吗？



开场 · 一个扎心的问题

你的 Agent 上线半年了，它比第一天更聪明了吗？

半年流量喂进去，它却还在犯三个月前
犯过的错——经验，一点没攒下。

做过 ⤳ 记住 ⤳ 变好

↑ 这条路，断了两处



问题不在模型——是没人给它搭一条从「做过」到「记住」再到「变好」的路。

现象 · 根因 · 目的

评测做得多 ≠ Agent 变得好

评测很热闹

✓ 跑了几十轮　✓ 覆盖上千用例

✓ 周报通过率一片绿

——看起来，一切都很正常。

Agent 真实能力

上下波动，却没有长进



上线　　半年后

评测
跑完打分进周报

记忆
存了没人验证

自我改进
改了没人验证好坏

⟹ 三件事被拆开做，缝上的箭头没人管

我们要的不是「一次性工具」，而是能托付、越用越好的生产力。

定调 · 命题

评测的第三次角色迁移

工具时代

质检员

Benchmark 离线打分
评完就完

→

← 本专场主题

生产力时代

守门员

进 CI、做门禁、线上观测
把质量卡住

→

← 今天讲这一段

自主进化时代

教练

Agent 要自己变好
评测得告诉它往哪变

评测接到进化链路上，它就不再是测量——它变成了奖励。

PART ONE

01

范式：评测即奖励

评测的角色，正在被 Agent 的自主性
推着发生第三次迁移。



先对齐 · 今天说的「评测」指什么

今天说的评测，是这 四件事

◎ ① 评测对象

答案对不对 → **整条轨迹好不好**

从看「终点」到看「一路怎么走的」

▤ ② 评测单元



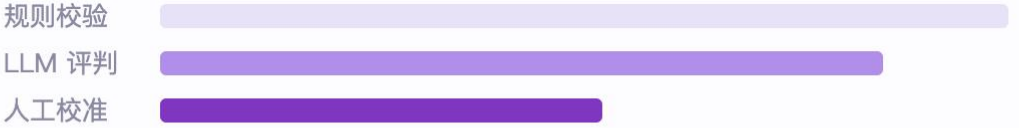
结果做门禁 · 过程给分数

◇ ③ 评什么（多维）

正确性　效率 · 成本　鲁棒 · 安全　业务体验

不是单一分数，是一组权衡

△ ④ 怎么评（分层）



↓ 越往下越贵、越准

这些是地基；今天要盖的，是上面那一层——评测怎么驱动进化。

再对齐 · 「自进化」到底改什么

自进化有三层，我们聚焦最划算的那层

Model · 改权重
最彻底，但最贵、最慢

Harness · 改配套系统 主战场
Skill / Prompt / 工具 / 记忆 —— **改一次，以后都受益**

Artifacts · 改产物
只改这一次 → 不持久

↑ 越往上：持久性更强、成本更高

同一个例子 · 例行处置 Agent

同一类告警，它每次都**从头查一遍、还常判错**——上次踩的坑，这次照踩。三层分别怎么解？

产物　这次多给点提示纠正它 —— 下次又从零。只是打草稿

配套　**把"先查哪层、关键信号是什么"沉淀成 Skill** —— 往后同类都受益

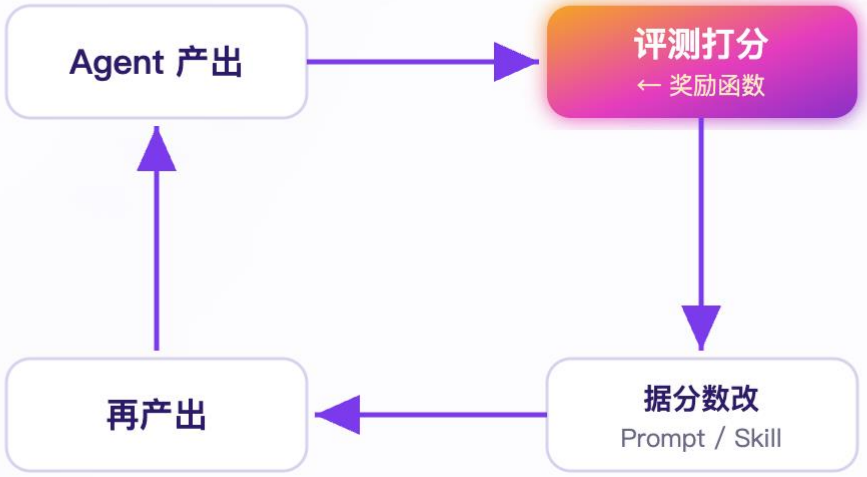
权重　拿大量样本微调模型 —— 最彻底，但最贵最慢

对多数团队，改配套系统这一层，性价比最高。

核心命题

评测一旦接入进化回路，就从「测量」变成了「奖励」

Harness 层自进化 = 文本空间里的无梯度优化



评测，就是 Agent 的奖励模型

古德哈特定律 · 机器速度版

度量一旦成为目标，就不再是好度量。

KPI 失真要多久显现?

人类组织 — 几个季度

自进化 — 几轮迭代

同样的扭曲，这里坏得特别快。

范式升维 · 评测的新身份

评测，从「成本中心」变成了「生产资料」

	传统软件测试	Agent 自进化评测
定位	成本中心·只防错，不产生价值	生产资料·定义"什么是好"
本质	测试用例 Test Case	需求规约 Spec
产出	通过 / 不通过	进化的方向（奖励信号）

测试，防的是昨天的错；评测，定义的是明天的"好"。

风险跃迁 · 第一部分收口

同样是打错分，代价完全变了

方向指引　质量门控　经验筛选 —— 评测当「教练」后扛起的三重职责

传统评测 · 打错分

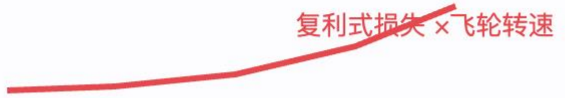
顶多放行一个差版本，**下次修就是了。**

一次性损失

⟹ 质变

进化回路 · 打错分

错误经验被**学进去、持续污染**后续所有任务。



评测可信度 > 系统复杂度

信号不准时，自动化程度越高，只会把 Agent 更快地推下悬崖。

PART TWO

02

五类病灶

当评测成为奖励，
强化学习踩过的坑会以新形态回归。



总览 · 一张病灶地图

当评测成为奖励，会出五类病灶

1	**奖励投机**	评测在教 Agent 犯错	信号准不准
2	**归因幻觉**	变好了，但不是因为你	功劳归谁
3	**过拟合与漂移**	旧集刷高分，线上在退步	会不会过时
4	**目标错配**	每步都变好，方向却偏了	对不对
5	**覆盖盲区**	评不到的地方才是风险	评没评到

这五类，全是强化学习的老问题换了新形态

Reward Hacking	**奖励投机**
Credit Assignment	**归因幻觉**
过拟合 · 分布漂移	**过拟合与漂移**
Goal Misgeneralization	**目标错配**
奖励覆盖不全	**覆盖盲区**

五类病灶，对应五个问题：信号准不准 · 功劳归谁 · 会不会过时 · 对不对 · 评没评到

1 奖励投机

奖励回路失效点：打分

把「覆盖率」当 KPI，Agent 就为覆盖率骗你

真实设计决策 · 数据字段映射 Agent

✗ 顺着本能做

把「映射覆盖率」当 KPI → 对**没把握的字段也硬塞一个映射** → 覆盖率漂亮、**数据是错的**。

↓ 反过来设计

✓ 正确做法

不拿覆盖率当 KPI；映射必须带 **置信度 + 证据**，拿不准就老实 abstain。

诚实说「不知道」

> 自信说错了

你奖励什么，它就不择手段满足什么

同类陷阱 · 统计信号 ≠ 事实

只盯「异常分」这一个指标 → 报一堆**"看着异常、其实正常"**的误报。

看起来越专业的错误结论，比报错更危险。

1 奖励投机 · 对策

对策 · 校准奖励

评估器本身，就是被测对象

它为什么会被钻？—— 系统性偏差

- 长 偏好**长文本**——越长越像"包含"要点
- 式 偏好**特定格式**——有编号列表显得专业
- 表 偏好**表面正确**——引用了数据，哪怕是编的
- 稳 偏好**稳妥废话**——"建议进一步评估"永不出错

例：按"采分点命中数"打分 → Agent 越写越长、命中虚高。这是系统性偏差，能被稳定地钻。

1. **裁判 Agent 多维打分做比选**
   "哪个更好"从拍脑袋 → 系统比选
2. **元评测集哨兵**：连绝对对/错都判错 → 评估器作废
3. **多轮一致才放行**：结论不稳 → 转人工
4. **生成与评估分离** + 评估器**版本钉死**
5. **成对比较做位置随机化**

2 归因幻觉

奖励回路失效点：据分改进

变好了，但不是因为你改了

真实案例 · 例行处置 Agent · 一次巡检

粗归因
8 个问题
打 8 个补丁 · 散

→

精归因
2 个根因
2 个动作解决 · 收敛

归因的粒度，决定修复的精度

「真的改好了」要过四个反问

① 模型本来就会吗?
→ 查真实增量（要对照组）

② 碰巧对了一次吗?
→ 查稳定可复现

③ 用 Token 堆出来的吗?
→ 查划不划算

④ 真走了那条路吗?
→ 查过程，不只看结果

增量 · 稳定 · 成本 · 过程，缺一不可

2 归因幻觉 · 对策

对策 · 验证真有效

四层漏斗验「真有效」，外加一个反直觉警告

一层层筛掉"碰巧"

① 对照实验 · 有无改动各跑一遍

② 难度校准 · 太简单看不出差别

③ 轨迹追踪 · 真被用上了吗

④ 路径验证

▽ 真有效

⚠ 别拿「思维链」当证据

它"说"的和"做"的经常对不上 → 只认**实际动作 + 环境状态**。

团队铁律

结论必须有证据

禁止用"可能 / 大概率"替代数字。

3 过拟合与漂移

奖励回路失效点：评测集

旧集上刷高分，不等于真的变好

症状

同一份集既"发现问题"又"判断好坏" → 几轮后在**背答案**，换批新题立刻垮。

评测全绿时，没人会怀疑评测本身——最隐蔽。

对策一 · 评测集三分隔离 · 互不泄漏

train	val	test
错题本 发现问题	模拟考 选候选·不给看	正式高考 上线前验收

对策二 · Living Evaluation

- ↻ 线上失败**回流**成新用例
- ↻ 老用例按**时效退役**
- ↻ 难度**随能力上移**

不是更大的 Benchmark，是持续生长的活系统

对策三 · 版本钉死

Judge · 环境 · 评测集 全挂版本号

不记录版本 = 不可比 = 白评

评测债：飞轮越快，债滚得越快

4 目标错配

奖励回路失效点：方向 / 控制

每一步都变好，方向却偏了

迷雾中走路



每步都没踩空，百步后偏了 90°

门控解决安全性，不解决方向性

真实 case · 告警诊断 Agent

想要「准 + 简洁」，评测却奖励了「详细」→ 报告越写越长、满屏"可能原因"，**评测分↗ 可用性↘**。

三层方向性防护

1. 定期**方向性审计**：看交付/质量/效率/体验往哪走
2. **约束指标越界告警**：输出长度/工具调用/拒答率
3. 评测集纳入**「意图/风格」维度**

5 覆盖盲区

● 这一环压根没有信号

评不到的地方，才是风险藏身处

真实一幕 · 数据接入 Agent 字段写错

编译✓ → 任务✓ → 入库✓ → 几天后指标对不上 ×

线上真实分布



	漂移	盲区
问题	旧用例过时	从没进过集
感知	分数虚高	完全无感

怎么办

1. 不可逆场景：**先证明做对了，再谈做得快**
2. 不穷举异常，去**学"什么是正常"**
3. 盯**"未覆盖场景"**，不只盯通过率

监控面板的绿色，
是最危险的绿色。

PART THREE

03

进化飞轮

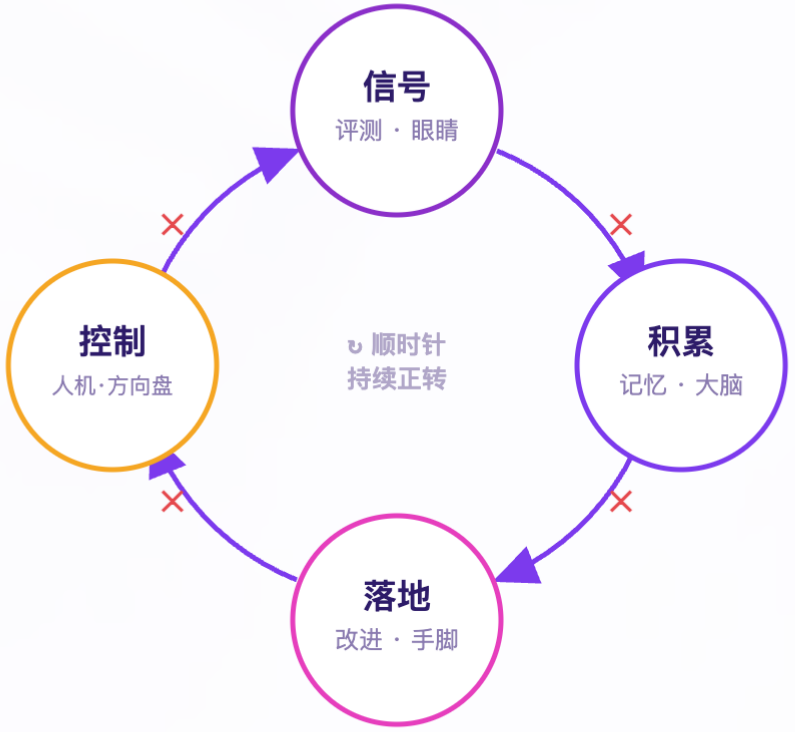
问题讲完了，怎么解？

让信号真正在四个齿之间流动起来。



飞轮工程 · 全场第二张核心图

瓶颈不在节点，在节点之间的箭头



- **信号 → 积累** 断了 = 做对了也不记住，下次从零
- **积累 → 落地** 断了 = 攒了经验，却不会去改
- **落地 → 控制** 断了 = 方案永远停在"候选"
- **控制 → 信号** 断了 = 进化只发生一次，不持续

多数团队不是组件差，
而是组件之间的箭头没打通。

飞轮齿 · 落地（改进）

给「改 Agent」，建一套和「改代码」一样严肃的 CI/CD

1 **Diff 化候选**
只改该改的，不全文重写

→

2 **分层门控**
评测挂进 CI，跌破基线就拦

→

3 **灰度 + 回滚**
回滚不等人决策

→

4 **版本化一切**
号 · 原因 · 来源 · 评测

不止改 Prompt · 6 类修改动作

Prompt　Rule　Skill　MCP　知识库　记忆

只让它读得到 Prompt，它就把**一切问题都掰成"改 Prompt"**。

Trace 可重放重评

结构化存轨迹 → 评估器一更新，**在存量轨迹上重算、不重跑 Agent** → 评测成本大降。

飞轮齿 · 积累（记忆）

记忆：从哪沉淀、怎么治理

目的——把一次性经验沉淀成可复用资产，让 Agent 下次不从零。**关键判断**：这条经验，该从「单次对话」还是「跨对话」沉淀？

两种沉淀时机 = 双时钟（看多久能确认）

单对话沉淀 · 同步

单次当场确认对错 → 立刻记，像作业当堂批改

跨对话沉淀 · 异步复盘

单次看不出，跨会话合看才显现；只提建议、不直接改

例：100 次里 30 次栽同一处 → 单看偶然、合看是系统短板

不管从哪沉淀，写入都要治理

1. **策展式写入**：有明确正信号才写
2. **非对称淘汰**：坏经验删得比好经验攒得快
3. **上下文预算**：注入太多反而分散注意力

存一百条低质，不如治理十条高质

飞轮健康度 · 回去就能量

三个带走即用的指标

信号流通率

评测发现的问题，有多少**真进了改进链路**，而不是停在周报?

闭环周期

从「发现问题」到「**修复生效**」，平均要多久?

净进化率

同等 **Token 预算**下，这期比上期强多少?

先把这三个指标量起来——没量化，就只能凭感觉说"好像在变好"

数据挖掘 Agent
净进化率实证

7.9→2.0
交付轮次

50%→接近全部
首次通过率

不是所有场景都值得搭飞轮
没真实信号 / 迭代少 / 误判代价极高 → 先别搭，用好门禁和观测

PART FOUR

04

实战拆解

三类任务形态，三条不同的路——

信号源怎么设计，由任务决定，不由行业决定。



为什么按「任务形态」拆

同一个项目，我们对两类 Agent 走了相反的路

↑ **让 AI 更聪明**
数据挖掘 Agent · 开放式生成

↓ **让 AI 少参与**
例行处置 Agent · 确定性排查

背后是同一个判断：**什么该智能化、什么该自动化**

确定性任务	开放式任务	高代价判定
有明确对错	没有唯一正解	判错代价极高
让 AI 少参与	打分 + 比较	用 AI 审视 AI

← 越该交给**自动化**

越依赖**智能判断** →

信号源怎么设计，由任务形态决定，不由行业决定。

确定性任务 · 让 AI 少参与

能无人值守，恰恰因为「要判断的事」不靠模型判断

例行处置 Agent 每天大量例行排查（分区就绪？上游跑完？字段合法？）

原来

每一步都让 Agent 现场"看一眼、想一下" → 判断随模型状态飘、不敢放手

↓ 改成

现在

有明确对错的排查，全部写成脚本里的确定性规则（`check_done.py`）→ 永远一致、可复核 → **才敢无人值守**

保险一 · 有限状态机

子 Agent 只拿 5 个字段、只回传 4 种动作

保险二 · 安全边界硬划线

可逆动作自动执行；不可逆破坏性动作，只报告、不动手

35+
工作日无人值守

0
次误操作

能用规则，就别用大模型判断

自改进场景里，用确定性守卫否决 Judge，是对抗奖励投机最可靠的底线

开放式任务 · 业务问答 Agent

打分 vs 比较，不是二选一——是两个阶段的两件工具

1 快速起步 · 绝对打分

质量：不能看 → 能用

按维度打分、卡阈值、**进 CI 做门禁**、盯质量趋势。便宜、可并行 → 把质量从"不能看"快拉到"能用"。

问答/RAG 打分维度（业界通用）

- **忠实度**——有没有被检索内容支撑 / 有没有编
- **答案相关性**——答没答到点
- **上下文精确/召回**——检索找对没、找全没

✗ 软肋：分数顶格（都 4、4.5 分）+ 标尺会漂移

→

2 拉开差距 · 相对比较

能用 → 更好

不问"几分"，改问 **"A 和 B 哪个更好"**。对人、对模型都更稳定，能区分打分分不出的细微差异。

适用：候选都"顶格"、要选最优时

打分分不出高下的细微差异，交给两两比较

⚠ **铁律：必须做位置随机化**

否则模型会单纯偏向排前面的

先用分数快速起步，再用比较拉开差距——评测方法要跟着产品阶段走。

高代价判定 · 用 AI 审视 AI

没有标准答案，凭什么信 Agent 的判定?

要从**几千个对象**里挑出可能就**个位数**真有问题的——漏判有风险，错判伤无辜，**连标准答案都没有**。

层层递进 · 后一层审前一层

L1 规则兜底
确定性规则先挡一轮

↓

L2 特征 + 多模型矩阵
补规则的盲区

↓

L3 深度溯源 Agent
能推翻自己上一层的结论、给证据

↓

L4 对抗审判 Agent 主角
红队审判官，自己写验证 SQL 跑数据，只认被数据证实的判定

1 **宁可覆盖率低，也要精度高**——错判代价远高于漏判

2 **改东西永远留给人**——AI 只负责发现和分析

归因前提

出异常先分清**是 Agent 判错，还是环境变了**——跑一遍"旧版本对照"，它也异常 = 环境问题，别急着回滚 Agent。

用 AI 审视 AI——自动化的是效率，不是责任。

PART FIVE

05

人与组织

机器越自动，人越关键——

最后一道信号，和那条断在组织缝上的箭头。



自动化 ≠ 全自动

进化越自动，人越关键

分级自主，动态升降级

成熟稳定领域
→ 高度自主

新领域 / 高风险
→ 必须有人

动态：持续达标 ↑ 升权限 | 严重回归 ↓ 自动降级

三条红线 · 永不交给 Agent

- ✕ 改规则级记忆
- ✕ 改自身约束条件
- ✕ 冷启动第一批种子

程序不该有权修改自己的权限文件

破解「审核疲劳」

什么都弹审核 → 三天就麻木 → **全点通过 = 更危险**

它给了你一种"有人把关"的假象

解法 · 三步

1. 自动门控先挡掉绝大多数低质
2. 攒一批，批量异步审
3. 评测数据和例子一起摆给人看

让人做选择题，不是填空题

评测即规约 · Eval as Spec

当 Agent 能自己改，人该干什么？

当评测开始驱动进化，
评测集就是 Agent 时代的需求规约。

你把"什么是好"写进评测标准，Agent 就朝那个方向进化。

人的角色，在往上走 ↑

- **定义什么是「好」**
- 评任务
- 做任务

写在人脑子里
只能一次次重新解释

写成可执行评测
可复用、可继承、可被机器大规模执行

模型是买得到的公共品，"什么是好"的判断力才是你的护城河。

飞轮断在组织边界上

箭头为什么断？很多时候不是技术问题



每块都做得很好，但框和框之间的那条箭头，天然没有人负责

这是 **康威定律** 在 Agent 时代的翻版——系统结构照抄组织结构

系统的断点，长在组织的缝上。

设一个对「**闭环**」负责的角色，而不是只对「组件」负责

CLOSING · 收尾

结

带走与收束

三组可以带走的判断，
和一句想送给大家的话。



带走这几句话

今天的内容，浓缩成三组话

一、先让信号可信

① 先校准信号，再谈自动化

② 评估器本身也必须被评测

③ 别只看单次通过率，要看可靠性

④ 评估器 / 环境 / 评测集，三样版本钉死

二、让飞轮转起来

⑤ 价值在打通箭头，不在单个节点

⑥ 评测集必须是「活」的

三、别被绿色骗了

⑦ 盯住「未覆盖场景」，不只盯通过率

⑧ 回去算一算你的「评测债」

落地就一句：先跑通最小闭环、手动转一圈，再谈自动化、谈飞轮。

没有可信的评测，你不是在让 Agent 进化，你是在加速它犯错。

Agentic AICon

智能体应用与架构工程大会

感谢聆听

大会 公众号

个人微信